

本科毕业论文（设计）

基于强化学习的人形机器人运动技能学习 与泛化研究

RESEARCH ON HUMANOID ROBOT MOTION SKILL LEARNING AND GENERALIZATION BASED ON REINFORCEMENT LEARNING

刘轩伟

哈尔滨工业大学

2026 年 5 月

☒ 毕业论文 ☐ 毕业设计

密级：公开

本科毕业论文（设计）

基于强化学习的人形机器人运动技能学习与泛化研究

本 科 生：刘轩伟

学 号：220320110

指 导 教 师：奚月平

专 业：自动化

学 院：深圳校区机器人与先进制造学院

答 辩 日 期：2026 年 5 月

学 校：哈尔滨工业大学

摘 要

人形机器人具备与人类相似的运动结构，在复杂环境作业、服务机器人和具身智能等场景中具有重要应用价值。然而，人形机器人自由度高、接触动力学复杂，传统控制方法难以直接获得兼具敏捷性、稳定性与泛化能力的全身运动技能。针对上述问题，本文围绕“专家数据预处理、动作重定向、强化学习动作跟踪与泛化测试”的技术流程，研究基于强化学习的人形机器人运动技能学习方法。

本文首先基于公开人体运动捕捉数据构建专家运动数据处理流程，通过人体模型与目标机器人之间的关键点拓扑映射、体型拟合、逐帧动作重定向和时序平滑，将人体运动序列转换为机器人可执行的关节空间参考轨迹；随后，在 Isaac Gym/MuJoCo 仿真环境中构建人形机器人全身动作跟踪任务，引入基于相位的参考状态表示、多模态轨迹误差度量和高斯核奖励函数，并采用近端策略优化算法训练控制策略；最后，针对高动态动作训练中容易出现的局部最优、物理约束冲突和策略保守化问题，设计参考状态初始化、动作偏离终止课程和安全正则项，以提升策略收敛效率和动作物理可行性。实验与阶段性结果表明，所构建的数据处理与强化学习训练框架能够完成多类人体动作到人形机器人的轨迹迁移，并使策略在仿真中跟踪给定参考动作，为后续跨仿真平台验证和复杂场景下的运动技能泛化奠定了基础。

关键词：人形机器人；强化学习；动作重定向；动作学习

Abstract

Humanoid robots have human-like kinematic structures and show broad application potential in complex operations, service robotics, and embodied intelligence. However, due to their high degrees of freedom and complex contact dynamics, conventional control methods find it difficult to directly acquire whole-body motion skills that are agile, stable, and generalizable. To address this problem, this thesis studies a reinforcement-learning-based method for humanoid robot motion skill learning following the technical pipeline of expert data preprocessing, motion retargeting, reinforcement-learning-based motion tracking, and generalization evaluation.

First, a motion data processing pipeline is constructed based on public human motion capture data. Through keypoint topology mapping between the human body model and the target robot, body shape fitting, frame-wise motion retargeting, and temporal smoothing, human motion sequences are converted into executable joint-space reference trajectories for the robot. Then, a whole-body motion tracking task is constructed in the Isaac Gym/MuJoCo simulation environment, where phase-based reference state representation, multimodal trajectory error metrics, and Gaussian-kernel reward functions are introduced, and the control policy is trained using the Proximal Policy Optimization algorithm. Finally, to address local optima, conflicts with physical constraints, and overly conservative policies that often arise in highly dynamic motion training, reference state initialization, a motion-deviation termination curriculum, and safety regularization terms are designed to improve convergence efficiency and physical feasibility. Experimental and preliminary results show that the proposed data processing and reinforcement learning framework can accomplish trajectory transfer from multiple categories of human motions to a humanoid robot and enable the policy to track given reference motions in simulation, laying a foundation for subsequent cross-simulator validation and motion skill generalization in complex scenarios.

Keywords: humanoid robot, reinforcement learning, motion retargeting, motion learning

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 研究目标与主要内容	5
1.3 论文结构安排.....	6
1.4 本文总体技术路线	6
第 2 章 相关研究综述	7
2.1 人形机器人敏捷控制与具身智能研究进展.....	7
2.2 基于强化学习的人体动作模仿与数据驱动范式	10
2.3 仿真训练中的模型误差与鲁棒性方法	11
2.4 本章小结	11
第 3 章 专家数据预处理与动作重定向	12
3.1 专家数据来源与处理目标	12
3.2 SMPL 运动解析与坐标规范化	13
3.3 运动学拓扑映射与体型拟合.....	14
3.4 基于仿真的专家数据清洗	16
3.5 两阶段时序动作重定向	17
3.6 轨迹平滑、接触修正与数据封装	18
3.7 本章小结	19
第 4 章 基于强化学习的运动跟踪方法	21
4.1 任务建模、观测空间与相位建模	21
4.2 策略结构与仿真闭环	23
4.3 优化目标与奖励设计	25
4.3.1 参考状态表示与误差度量.....	25
4.3.2 奖励函数设计.....	26
4.4 稳定化机制与数据回收	28
4.4.1 终止课程学习.....	28
4.4.2 参考状态初始化	29

4.4.3 域随机化与训练鲁棒性	29
4.4.4 轨迹闭环与数据回收	30
4.5 本章小结	30
第 5 章 实验设计与结果分析	31
5.1 实验设置与评价方法	31
5.2 主要实验结果与案例分析	33
5.3 鲁棒性与泛化实验	35
第 6 章 总结与展望	39
6.1 结果讨论与总体总结	39
6.2 研究局限性	39
6.3 未来工作展望	40
参考文献	41
攻读学士学位期间取得创新性成果	45
哈尔滨工业大学本科毕业论文（设计）原创性声明和使用权限	46
致 谢	47

第 1 章 绪论

1.1 研究背景与意义

人形机器人由于具有接近人类的身体结构和运动形态，被认为是最有潜力在真实人类环境中执行复杂任务的机器人形态之一。与传统工业机器人主要服务于结构化生产线不同，人形机器人能够在面向人类设计的空间中完成移动、操作、交互与服务等多样化任务，例如室内服务、灾害救援、医疗辅助以及危险环境巡检等。因此，使人形机器人具备稳定、灵活且可扩展的全身运动能力，是实现通用具身智能和未来服务机器人的重要基础，典型应用场景与任务形式如图 1-1 所示。



图 1-1 人形机器人典型应用场景示意图

除应用需求持续扩大外，近年来国内外人形机器人本体平台也进入快速迭代阶段。英国 Engineered Arts 推出的 AMECA、美国的 Apollo、Optimus、Atlas、Figure 01，以及国内的 Fourier GR-1、宇树 G1、Walker S1、CyberOne、AgiBot 等平台，分别在交互展示、双足运动、灵巧操作和通用作业等方向展开探索。不同产品在驱动形式、整机尺寸、自由度配置、上肢能力和目标应用场景上存在

明显差异，这也反映出当前人形机器人仍处于技术路线并行演进的阶段。典型国内外人形机器人产品形态如图 1-2 所示。




图 1-2 国内外代表性人形机器人产品示意图

过去较长时间内，人形机器人研究主要关注稳定行走、速度跟踪和基础越障等移动能力。这类研究通常将下肢视为移动平台，将控制重点放在质心稳定、足端接触和抗扰恢复上，而对躯干、上肢和全身姿态表达能力的利用相对有限。随着硬件平台、物理仿真器和学习算法的发展，研究者开始关注更具挑战性的全身敏捷运动，例如跳跃、快速转向、舞蹈、运动技能和人机交互动作等^[1-4]。这些动作不再只是“保持不摔倒”的移动任务，而是要求机器人在多关节协同、多接触切换和动态平衡之间保持一致的运动风格与物理可行性。

然而，与轮式机器人或固定基座机械臂相比，人形机器人在控制上面临更为严峻的挑战。一方面，人形机器人通常具有数十个自由度，其运动控制涉及腿部支撑、躯干姿态、手臂摆动和头部朝向等多部分协同；另一方面，行走、跳跃和转身过程中会频繁发生单脚支撑、双脚支撑、腾空、落地等接触模式切换，系统呈现强非线性、强耦合和欠驱动特性。此外，地面接触、摩擦不确定性、执行器带宽限制和传感器噪声等因素会进一步增加控制难度。因此，如何在高自由度、多接触和复杂动力学约束条件下实现自然、稳定且敏捷的全身运动控制，仍是机器人领域的重要问题。

传统控制方法主要依赖精确的动力学建模、轨迹规划与反馈控制器设计，例如基于模型预测控制（Model Predictive Control, MPC）、零力矩点（Zero Moment Point, ZMP）稳定性分析以及逆动力学控制等方法。这类方法具有较好的可解

释性，在结构明确、任务边界清晰的场景中能够取得稳定效果。但当任务扩展到跳跃、快速踢腿、连续转身等高动态动作时，传统方法往往需要复杂的接触序列设计、人工调参和分阶段控制逻辑。对于动作类别丰富、姿态变化剧烈的人形机器人运动技能学习而言，完全依赖手工设计的控制框架难以充分利用大规模运动数据中的先验知识。

近年来，深度强化学习（Deep Reinforcement Learning, DRL）为高维连续控制问题提供了数据驱动的解决思路。通过在物理仿真环境中进行大规模并行交互，策略网络能够直接学习从机器人状态到控制指令的映射，并在奖励函数约束下逐步形成满足动力学规律的运动模式。Isaac Gym 等图形处理器（Graphics Processing Unit, GPU）并行仿真平台显著提升了机器人强化学习的采样效率，并推动了分钟级并行训练范式的发展^[5-7]，近端策略优化（Proximal Policy Optimization, PPO）等算法则为连续控制策略训练提供了相对稳定的优化框架^[8]。在此基础上，基于学习的方法已经在人形机器人行走、跳跃、跑酷和复杂地形运动中展现出较强潜力^[9-14]。

与此同时，具身智能与大模型技术的快速发展正在改变人形机器人的研究范式。近期综述指出，大语言模型、视觉 Transformer、视觉语言模型以及具身多模态大模型，正在持续增强机器人在语言理解、场景感知、常识推理和任务规划等方面的能力^[15]。对于人形机器人而言，这意味着其控制问题不再局限于“如何稳定迈步”，而是逐步扩展为“如何理解任务语义、感知开放环境，并将高层意图转化为自然的全身动作执行”。不过，高层语义能力的提升并不能直接替代底层运动控制。面对高自由度身体结构、频繁接触切换和动态平衡约束，机器人仍然需要可靠的动作表示、可执行的参考轨迹以及稳定的闭环控制策略，才能将感知和规划结果真正落实为物理世界中的可行动作。

另一方面，人体运动数据为人形机器人学习自然运动提供了重要来源。人体表面形状动作捕捉档案（Archive of Motion Capture as Surface Shapes, AMASS）等大规模人体运动捕捉数据集将不同来源的动作捕捉（Motion Capture, MoCap）数据统一到多人线性蒙皮模型（Skinned Multi-Person Linear, SMPL）参数化人体模型中，包含丰富的根节点位姿、关节姿态和体型参数^[16]。DeepMimic 证明了强化学习可以通过跟踪参考动作来获得高质量的物理角色技能^[17]，后续工作进一步探索了对抗运动先验、可复用技能嵌入、风格化运动控制以及基于人体参考的全身控制方法^[18-21]。这些研究表明，将人体运动先验与物理仿真中的闭环控制结合，是获得自然、协调和高动态运动技能的有效路径。

从这一视角看，大模型技术与人体动作模仿并非割裂的两条路线，而是可以形成互补关系。大模型擅长处理开放场景中的语义理解、跨模态关联和任务分解问题，人体运动数据则为机器人提供自然、连贯且符合人类运动习惯的动作先验^[15]。对于本文关注的敏捷全身运动技能学习任务而言，优先解决专家数据预处理、动作重定向和强化学习稳定跟踪问题，有助于为后续更高层级的语言条件控制、视觉条件控制或多模态任务控制建立可复用的底层运动能力基础。

尽管如此，直接利用人体运动数据驱动人形机器人仍面临若干关键挑战。首先，人体骨架与机器人结构在拓扑关系、连杆比例、关节轴定义和自由度数量上存在显著差异，原始人体姿态无法直接作为机器人关节目标，需要通过动作重定向（motion retargeting）转换为机器人可执行的参考轨迹^[14,22]。其次，人体运动数据通常只提供运动学信息，缺少接触力、关节力矩和执行器约束等动力学信息，若在仿真中直接跟踪，容易产生足端滑移、关节越界、扭矩异常或整体失稳等问题^[20,22]。再次，高动态动作训练过程中，策略可能通过降低动作幅度、提前终止或保持保守姿态来获得局部较高奖励，导致模仿精度和动作表现力不足。此外，策略在不同初始相位、外部扰动和环境变化下的鲁棒性仍需专门设计和评估^[17,23-24]。上述关键挑战的归纳如图 1-3 所示。




图 1-3 人体数据驱动人形机器人运动技能学习的关键挑战

针对上述问题，本文研究基于强化学习的人形机器人运动技能学习方法，重点关注人体专家数据向机器人可执行轨迹的转换、高保真物理仿真中的整身

动作跟踪学习，以及策略鲁棒性与泛化能力的提升机制。本文暂不以真实机器人部署为主要目标，而是将研究重点放在仿真环境中的数据处理、参考轨迹构建、强化学习任务建模和动作跟踪效果验证上。通过构建统一的技术流程，本文旨在为人形机器人学习多样化全身运动技能提供可复现的实现框架和实验基础。

1.2 研究目标与主要内容

本文面向人形机器人复杂运动技能学习任务，构建一套由专家数据预处理、动作重定向、强化学习动作跟踪和策略泛化评估组成的技术流程。研究目标是在高保真仿真环境中，使人形机器人能够跟踪由人体运动数据转换得到的参考动作，并在扰动和环境变化下保持较好的稳定性。

本文的主要研究内容包括以下三个方面。

第一，研究专家数据预处理与动作重定向方法。针对 AMASS 等人体运动捕捉数据，本文从 SMPL 参数化人体模型出发，解析人体根节点位姿、关节旋转与身体形状参数，建立人体关键点与目标机器人连杆关键点之间的拓扑对应关系。进一步结合体型拟合、运动学优化、关节范围约束、时序平滑以及异常片段清洗等步骤，将原始人体动作序列转换为机器人可执行、时序连续且满足基本物理可行性的参考轨迹，为后续强化学习动作跟踪任务提供高质量专家动作输入。

第二，构建基于强化学习的人形机器人整身动作跟踪方法。围绕目标机器人建立高保真仿真训练环境，统一定义状态观测、动作输出、低层比例-微分 (Proportional-Derivative, PD) 控制器和外部扰动注入方式，并以重定向后的参考轨迹作为专家动作输入，设计相位驱动的动作跟踪任务。在此基础上，综合构建观测空间、动作空间、参考状态表示、奖励函数以及 PPO 优化目标，使策略能够在长时序执行过程中实现对参考动作的稳定跟踪，并保持较好的动态平衡和动作自然性^[5]。

第三，研究策略稳定化与实验评估方法。针对动作跟踪过程中容易受到初始状态偏差、接触扰动和环境变化影响的问题，本文引入参考状态初始化、课程学习、终止机制和域随机化等训练稳定化策略，以提升策略的鲁棒性与泛化能力。同时，围绕动作跟踪精度、训练收敛速度、执行稳定性、抗扰能力和泛化性能等指标设计系统实验，并结合可视化结果与典型案例分析，对所提方法的有效性和适用范围进行验证。

1.3 论文结构安排

本文后续章节安排如下：第2章介绍人形机器人运动技能学习的相关研究；第3章给出专家数据预处理与动作重定向方法；第4章阐述基于强化学习的动作跟踪任务、观测与动作建模、PPO优化目标、奖励函数和稳定化训练机制；第5章给出实验设计、评价指标与实验结果分析；第6章对全文工作进行总结，并从研究局限性与未来工作展望两个方面展开讨论。

1.4 本文总体技术路线

本文总体方案包括三个阶段。

第一阶段为专家数据预处理。选取人体运动捕捉数据作为专家动作来源，提取 SMPL 运动参数，建立人体关键点与目标人形机器人连杆之间的拓扑对应关系^[22]。通过静态体型拟合得到与机器人几何尺寸更接近的人体表示，再通过逐帧动作重定向求解机器人关节角和根位姿轨迹。

第二阶段为强化学习动作跟踪。将重定向后的参考轨迹封装为标准化动作库，在仿真环境中实时采样参考状态。策略网络根据机器人本体状态、动作相位和参考误差输出控制动作，底层 PD 控制器将动作转换为关节控制命令。奖励函数围绕刚体位置、姿态、关节角、关节速度和安全正则项构建，训练算法采用 PPO。

第三阶段为鲁棒性与泛化测试。在训练完成后，向仿真环境中加入外部推力、传感器噪声、控制延迟和不同地形几何，评估策略在扰动条件下的动作保持能力。同时可进行跨仿真平台测试，用于检查动作跟踪方法对不同物理引擎和参数设置的敏感性。

本文基于人体数据与强化学习的人形机器人运动技能学习总体方案如图 1-4 所示。




图 1-4 基于人体数据与强化学习的人形机器人运动技能学习总体方案

第2章 相关研究综述

在第1章明确了本文关注的人形机器人运动技能学习问题之后，本章进一步从相关研究层面展开梳理。需要回顾人形机器人敏捷控制、全身遥操作、大模型驱动具身智能以及人体动作模仿等研究进展，以明确本文工作的技术脉络和切入点，并为后续方法章节提供清晰的研究背景支撑。

2.1 人形机器人敏捷控制与具身智能研究进展

人形机器人全身运动控制的核心目标，是在满足动力学约束和接触稳定性的前提下，使机器人完成自然、协调且具有任务适应性的运动。早期研究主要集中在基础移动控制任务，例如平地行走、速度跟踪和简单避障。在这类任务中，下肢通常被视为实现移动的主要机构，控制策略更关注质心稳定和足端接触，而对上肢、躯干和全身姿态表达能力的利用相对有限。

近年来，随着高性能人形机器人硬件和并行物理仿真平台的发展，研究者开始关注更复杂的全身运动技能。基于强化学习的方法已经在双足行走、快速移动、跳跃和复杂地形运动中取得进展^[1-2,9-13,25]。这类方法通常在仿真环境中进行大量试错，通过奖励函数引导策略形成稳定运动模式。与传统控制方法相比，学习型控制能够在复杂接触和高维状态空间下自动搜索控制规律，减少对人工设计步态机和接触序列的依赖。

除基础移动能力外，整身控制和表达性动作逐渐成为人形机器人研究的重要方向。相关工作尝试让机器人完成舞蹈、上肢跟随、全身远程操作、移动操作和高动态运动等任务^[3-4,22,26-28]。这类任务要求策略同时协调下肢支撑、躯干姿态和上肢运动，不仅要保持动态平衡，还要尽可能复现参考动作的节奏、幅度和姿态风格。因此，人形机器人控制问题正在从“稳定行走”扩展到“自然、敏捷、可表达的全身运动”。其中，全身遥操作任务通常需要同时处理人体测量信息、动作重定向、机器人局部反馈以及环境感知反馈，其典型闭环架构如图2-1所示。

与普通移动控制相比，敏捷全身运动具有更高难度。首先，机器人自由度高，状态空间和动作空间维度大，简单的人工控制规则难以覆盖全部运动模式。其次，足端接触状态频繁变化，腾空、落地和支撑切换会引入强非线性冲击。再

次，许多动作具有明显的时序结构，某一时刻的控制误差会累积到后续相位，导致整段动作失败。因此，本文将动作表示、参考轨迹构建和强化学习闭环控制作为一个整体问题进行研究。




图 2-1 人形机器人全身遥操作任务的典型系统架构示意图

随着具身智能研究的持续升温，大模型正逐渐成为连接机器人感知、认知、规划与控制的重要技术底座。相关综述指出，大语言模型、视觉 Transformer、视觉语言模型、视觉生成模型以及具身多模态大模型，已经开始在环境理解、任务推理、语言交互、动作生成和行为控制等环节发挥作用^[15]。对于人形机器人而言，这类模型的意义在于：一方面，它们能够利用互联网规模数据获得较强的语义先验和跨模态关联能力；另一方面，它们可以把开放环境中的图像、文本、语音和视频信息统一到同一决策框架中，从而提升机器人在非结构化场景下的任务适应性。

现有大模型驱动的人形机器人研究大体可归纳为三类技术路线。第一类是分布式模块化路线，即分别使用不同模型处理感知、规划、决策和控制等子任务，再通过接口或中间表示进行级联。这一路线的优点是结构清晰、可解释性较强，也便于将现有视觉模型和语言模型快速接入机器人系统；其局限在于模块间误差容易累积，推理延迟和接口对齐问题会影响整机闭环性能。第二类是端到端一体化路线，即直接从视觉和语言输入映射到动作输出，尝试利用视觉-语




图 2-2 一种基于分布式多模态大模型的人形机器人作业技术路线图

言-动作模型统一高层语义与低层控制。该路线具备较强的任务泛化潜力，但通常依赖大规模机器人交互数据和高质量标注，且在高频、强接触的人形机器人全身运动控制上仍面临训练成本高和稳定性不足的问题。第三类是云边端协同路线，即将高算力语义推理、长期知识存储和低时延执行控制分散到云端、边缘端和本体端协同完成，以平衡算力、隐私和实时性需求^[15]。

其中，分布式多模态大模型路线的一个典型思路，是围绕传感器、控制器和执行器构建分层的感知、认知、决策与控制模型，并通过迭代训练方式实现任务语义理解到执行控制的逐级映射。其代表性技术框架如图 2-2 所示。

从本文研究主题来看，大模型研究进展为人形机器人动作学习提供了重要启发，但并未直接解决敏捷全身运动中的核心困难。大模型更擅长回答“做什么”和“为什么这样做”，而本文关注的动作跟踪与技能学习更强调“如何在动力学约束下稳定做到”。特别是在跳跃、快速转向、舞蹈等高动态动作中，机器人必须同时满足关节限位、接触约束、姿态协调和时序连续性要求，因此仍需要依赖高质量的人体动作先验、合理的动作重定向方式以及物理仿真中的强化学习闭环控制。也就是说，大模型可以为人形机器人提供更强的高层语义条件和任务上下文，而稳定的底层运动技能学习框架则是这些高层能力落地的基础。

2.2 基于强化学习的人体动作模仿与数据驱动范式

在物理角色动画领域,基于强化学习的动作模仿已经被证明能够生成自然且具有动态一致性的运动。DeepMimic 通过设计参考姿态、速度、末端位置和质心等跟踪奖励,使物理角色能够学习翻滚、踢腿和后空翻等复杂技能^[17]。随后,对抗运动先验(Adversarial Motion Priors, AMP)、对抗技能嵌入(Adversarial Skill Embeddings, ASE)、MaskedMimic 和 Perpetual Humanoid Control 等方法进一步研究了风格化运动先验、可复用技能表示、部分观测条件下的动作补全和长时序角色控制^[18-21]。这些研究说明,参考动作不仅可以作为监督目标,还可以作为强化学习中的运动先验,约束策略在物理环境中探索合理动作。

将上述思想应用到机器人控制时,需要进一步考虑机器人结构和执行器约束。机器人不是理想化物理角色,其关节自由度、关节限位、执行器带宽和足端接触模型均会限制动作可行性。已有研究开始将人体参考动作引入人形机器人控制,例如利用人体动作进行全身远程操作、整身模仿或带有人体参考的运动控制^[14,22,28]。这类方法的共同特点是先构建适合机器人执行的参考轨迹,再通过强化学习或策略优化获得闭环控制器。

本文采用的技术路线与上述研究具有一致思想:首先从人体运动数据中提取全身运动先验,再将其转化为机器人可执行的参考轨迹,最后在物理仿真环境中训练策略进行跟踪。与仅学习行走速度指令的任务相比,动作模仿任务需要同时关注根节点运动、关节姿态、刚体位置、速度和动作相位,因此对观测设计、奖励函数和初始化策略提出了更高要求。

为了让机器人获得复杂且自然的运动技能,本文采用基于真实人体运动数据的模仿学习思路。人体运动捕捉数据通常包含丰富的动作类别和连贯的全身姿态变化,能够为机器人提供高质量的运动先验。典型流程包括人体运动数据解析、动作重定向、参考轨迹生成和基于强化学习的动作跟踪^[20,22]。

在数据层面,AMASS 等大规模人体运动捕捉数据集将不同来源的人体动作统一表示为 SMPL 参数化身体模型^[16]。该表示能够提供人体根位姿、关节旋转和身体形状参数,便于进行跨数据集处理。但由于人体与机器人在骨骼拓扑、关节轴定义和连杆尺寸上存在差异,需要通过动作重定向将人体关键点运动映射到机器人关节空间。

动作重定向是连接人体数据和机器人控制的关键环节。常见做法不是逐关节复制人体角度,而是建立人体关键点与机器人连杆之间的空间对应关系,通

过优化使机器人关键点尽可能贴合人体关键点轨迹。这样可以在一定程度上解开人体骨骼和机器人关节定义不一致的问题。与此同时，还需要考虑机器人关节上下限、根节点高度、足端接触和轨迹平滑等约束，否则生成的参考动作虽然在几何上接近人体姿态，却可能在物理仿真中难以稳定跟踪^[14,22]。

在训练层面，基于相位的强化学习动作跟踪是一种常见范式。策略网络不仅接收机器人自身的关节状态、速度和姿态信息，还接收动作相位和参考状态误差，使策略能够感知当前应当执行的动作片段。为提升训练稳定性，通常还需要引入非对称 Actor-Critic 架构、参考状态初始化、课程学习和动作偏离终止机制^[17]。此外，生成对抗模仿学习等方法也为从专家数据中学习策略提供了重要思路^[29]。本文重点采用显式轨迹跟踪奖励，而不是对抗判别器奖励，原因在于显式误差项更便于结合刚体位置、关节角和速度等可解释指标进行调试。

2.3 仿真训练中的模型误差与鲁棒性方法

人形机器人强化学习通常依赖物理仿真器完成大规模采样。MuJoCo、Isaac Gym 和 Genesis 等平台能够提供刚体动力学、接触求解和并行训练能力，为复杂机器人控制提供了重要工具^[5,30-31]。但仿真模型仍会受到连杆惯量、摩擦参数、接触模型和执行器响应等误差影响。即使本文主要关注仿真环境中的动作学习，这些模型误差也会影响策略训练稳定性和跨仿真器复现能力。

现有研究中常见的鲁棒性方法包括系统辨识、域随机化和残差学习。系统辨识通过实验数据估计质量、阻尼、摩擦和电机响应等参数，以获得更准确的仿真模型^[32-34]；域随机化则在训练时随机扰动物理参数，使策略适应一定范围内的模型变化^[23-24,35]；残差学习通过额外模型补偿基础控制器或动力学模型的不足^[36-38]。对于本文的研究范围而言，这些方法主要作为提升策略稳定性和泛化性的参考，而不是本文工作的核心内容。本文更关注如何先在仿真中形成稳定、可复现的动作跟踪流程。

2.4 本章小结

本章分析了人形机器人敏捷运动控制、基于强化学习的动作模仿、人体运动数据重定向以及仿真训练鲁棒性等相关研究。后续章节将围绕专家数据预处理、强化学习动作跟踪方法以及实验验证三个部分展开。

第3章 专家数据预处理与动作重定向

本章首先需要解决的核心问题是：如何将人体专家动作稳定、合理地转换为机器人可执行的参考轨迹。由于人体运动数据与人形机器人在骨架拓扑、连杆比例、关节自由度和物理约束上存在显著差异，若缺少系统的数据预处理和动作重定向步骤，后续强化学习很难获得高质量的参考目标。为此，本章围绕专家数据来源、SMPL 运动解析、关键点拓扑映射、基于仿真的数据清洗以及两阶段时序动作重定向方法展开，构建后续动作跟踪训练所需的参考动作库。

3.1 专家数据来源与处理目标

专家数据质量直接决定后续强化学习动作跟踪任务的上限。本文以 AMASS 数据集中的人体运动捕捉序列作为主要专家动作来源^[16]。



图 3-1 AMASS 数据集

AMASS 将多个来源的 MoCap 数据统一到 SMPL 参数化人体模型中，能够提供根节点平移、根节点旋转、人体关节姿态和体型参数等信息。对于来自普通视频的人体动作，也可以先利用三维人体重建方法恢复 SMPL 运动参数^[39-40]，

再接入本文后续的数据处理流程。因此，本章讨论的预处理方法并不依赖某一种原始采集设备，而是面向统一的 SMPL 运动表示。

设一段人体专家动作序列表示为

$$\mathcal{D}_H = \{\mathbf{p}_t^h, \mathbf{R}_t^h, \boldsymbol{\theta}_t^h, \boldsymbol{\beta}^h, \Delta t\}_{t=1}^T, \quad (3-1)$$

其中， $\mathbf{p}_t^h \in \mathbb{R}^3$ 为人体根节点在世界坐标系下的位置， $\mathbf{R}_t^h \in SO(3)$ 为根节点朝向， $\boldsymbol{\theta}_t^h$ 为 SMPL 关节姿态参数， $\boldsymbol{\beta}^h$ 为体型参数， Δt 为相邻帧的时间间隔， T 为动作总帧数。本文数据处理的目标，是将上述人体运动序列转换为机器人可执行的参考轨迹

$$\mathcal{D}_R = \{\mathbf{p}_t^r, \mathbf{R}_t^r, \mathbf{q}_t^r, \dot{\mathbf{q}}_t^r, \boldsymbol{\chi}_t^r\}_{t=1}^T, \quad (3-2)$$

其中， $\mathbf{q}_t^r$ 和 $\dot{\mathbf{q}}_t^r$ 分别为机器人关节角与关节速度， $\boldsymbol{\chi}_t^r$ 表示由正向运动学计算得到的机器人关键刚体状态。该轨迹不仅需要在几何形态上接近人体动作，还必须满足机器人关节限位、连杆尺寸、接触高度和时间连续性等约束，否则后续强化学习策略会在跟踪阶段遇到不可达目标。

AMASS 数据集中包含多样化的人体体型和动作姿态，其动作数据示例如图 3-1 所示。本文将专家数据预处理划分为五个环节：原始运动解析、关键点拓扑映射、基于仿真的数据清洗、两阶段动作重定向以及轨迹平滑与数据封装，整体流程如图 3-2 所示。




图 3-2 专家数据预处理与动作重定向总体流程示意图

3.2 SMPL 运动解析与坐标规范化

SMPL 模型通过体型参数和姿态参数生成具有固定拓扑的人体网格与骨架关键点。为了便于与机器人模型建立对应关系，本文不直接使用人体网格顶点，而是从 SMPL 运动中提取骨盆、膝、踝、肩、肘、腕等与机器人连杆具有明确语义对应的关键点。记第 t 帧第 i 个人体关键点为

$$\mathbf{x}_{i,t}^h = F_i^{\text{SMPL}}(\mathbf{p}_t^h, \mathbf{R}_t^h, \boldsymbol{\theta}_t^h, \boldsymbol{\beta}^h), \quad (3-3)$$

其中 $F_i^{\text{SMPL}}(\cdot)$ 表示 SMPL 正向运动学和蒙皮计算后得到的第 i 个关键点位置。该

表达式说明人体关键点并不是独立变量，而是由根位姿、关节姿态和体型共同决定。

不同数据源中的世界坐标系定义可能并不一致。例如，部分动作数据以人体初始朝向作为前进方向，部分数据则保留采集设备的全局坐标。为减少这种差异对重定向结果的影响，本文首先将动作序列平移到以初始根节点为参考的局部坐标系中：

$$\bar{\mathbf{p}}_i^h = \mathbf{p}_i^h - \mathbf{p}_1^h. \quad (3-4)$$

随后根据机器人默认站立方向，对根节点朝向进行水平旋转对齐，使人体前进方向与机器人模型的前向轴一致。该处理不会改变人体各关节的相对运动，只是统一后续优化问题的坐标基准。

为了避免帧率差异造成参考轨迹与仿真控制频率不匹配，本文对人体序列进行时间重采样。设原始动作时间为 $t_k = k\Delta t$ ，目标控制周期为 Δt_{ctrl} ，则新时间索引 $\tau_m = m\Delta t_{\text{ctrl}}$ 处的关节姿态和根位姿由相邻帧插值得到。平移量采用线性插值，旋转量采用球面线性插值，从而避免欧拉角插值带来的不连续问题。

3.3 运动学拓扑映射与体型拟合

动作重定向的第一步是建立人体模型与机器人模型之间的空间对应关系。由于人体骨架和机器人机构并不存在一一对应的关节定义，本文不采用逐关节角度复制，而是选取一组具有稳定语义的身体部位建立关键点集合^[14,22]。设 $\mathcal{I}$ 为匹配关键点下标集合，每个元素 $i \in \mathcal{I}$ 对应一对人体关键点和机器人连杆参考点。例如，人体骨盆对应机器人 pelvis 连杆，人体左膝对应机器人 left knee link，人体左踝对应机器人 left ankle link。

本文所使用的人形机器人结构及主要关键部位如图 3-3 所示。在此基础上，SMPL 人体关键点与机器人连杆关键点之间的拓扑映射关系如图 3-4 所示。

由于 SMPL 默认人体体型与目标机器人连杆比例不同，若直接逐帧优化机器人关节，重定向结果容易出现上肢或下肢长度不匹配的问题。因此，本文先进行静态体型拟合，在初始站立姿态下求解一个更接近目标机器人几何比例的 SMPL 体型参数。设机器人在默认姿态下第 i 个匹配关键点位置为 $\mathbf{x}_i^{r,0}$ ，SMPL 在体型参数 $\boldsymbol{\beta}$ 和全局缩放系数 s 下的对应关键点位置为 $\mathbf{x}_i^{h,0}(\boldsymbol{\beta}, s)$ ，则体型拟合损失定义为




图 3-3 本文所用人形机器人结构示意图




图 3-4 SMPL 关键点与机器人连杆关键点的拓扑映射示意图

$$\mathcal{L}_{\text{shape}} = \frac{1}{|I|} \sum_{i \in I} w_i \|\mathbf{x}_i^{\text{r},0} - \mathbf{x}_i^{\text{h},0}(\boldsymbol{\beta}, s)\|_2^2 + \lambda_{\beta} \|\boldsymbol{\beta}\|_2^2. \quad (3-5)$$

式中， w_i 为第 i 个关键点的权重，用于提高骨盆、膝、踝等影响全身支撑结构的关键点重要性； λ_{β} 为体型正则化系数，用于抑制过大的体型参数偏移。第一项衡量机器人关键点与人体关键点之间的平均欧氏距离，第二项则约束优化后的 SMPL 体型仍处于合理人体形状范围内。

优化式 (3-5) 后得到的体型参数记为 $\boldsymbol{\beta}^*$ 。该参数不是最终机器人动作，而是为后续逐帧重定向提供几何一致的人体参考，使机器人和人体之间的肢体比例差异在进入动态序列优化前得到初步消除。

3.4 基于仿真的专家数据清洗

原始人体动作或视频重建动作通常只保证运动学上的可见姿态合理，并不一定满足机器人控制所需的物理可行性。高动态动作中常见的问题包括足端穿地、根节点高度突变、膝踝姿态异常、相邻帧速度过大以及由于重建噪声导致的短时抖动。若将这些片段直接作为强化学习参考轨迹，策略可能会学习到不可实现的目标，甚至通过异常姿态获得局部奖励。

参考物理角色动作跟踪中的数据验证思路^[20,22]，本文在重定向前后均设置数据清洗步骤。首先在运动学层面剔除明显异常帧，判断条件包括根节点高度范围、关键点速度上界和关节角连续性。以关键点速度为例，若

$$\max_{i \in I} \frac{\|\mathbf{x}_{i,t}^{\text{h}} - \mathbf{x}_{i,t-1}^{\text{h}}\|_2}{\Delta t} > v_{\text{max}}, \quad (3-6)$$

则说明该帧附近可能存在重建跳变，需要进行平滑、插值修复或从动作库中剔除。

其次，本文利用仿真环境对重定向候选轨迹进行可跟踪性验证^[20,22]。设策略或跟踪器在仿真中执行候选参考动作后得到的机器人刚体状态为 $\hat{\mathcal{X}}_t^{\text{r}}$ ，候选参考刚体状态为 $\mathcal{X}_t^{\text{r}}$ ，则整段动作的平均跟踪误差可写为

$$E_{\text{track}} = \frac{1}{T|\mathcal{B}|} \sum_{t=1}^T \sum_{j \in \mathcal{B}} \|\hat{\mathbf{x}}_{j,t}^{\text{r}} - \mathbf{x}_{j,t}^{\text{r}}\|_2, \quad (3-7)$$

其中 $\mathcal{B}$ 为用于评估的机器人刚体集合， $\hat{\mathbf{x}}_{j,t}^{\text{r}}$ 和 $\mathbf{x}_{j,t}^{\text{r}}$ 分别表示仿真执行状态和参考状态中的第 j 个刚体位置。当 E_{track} 超过给定阈值，或者动作执行过程中发生明显失稳、穿模和异常接触时，该动作片段不进入最终专家动作库。经过该步骤后保留下来的数据记为 $\mathcal{D}_{\text{H}}^{\text{clean}}$ 。

3.5 两阶段时序动作重定向

完成体型拟合和数据清洗后，需要将完整人体动作序列转换为机器人关节空间轨迹。本文采用“根位姿对齐”和“关节姿态优化”相结合的两阶段方式^[22]。第一阶段处理全局位移和朝向，使机器人根节点运动与人体运动的整体趋势一致；第二阶段在每一帧内优化机器人关节角，使关键连杆尽可能贴合人体关键点。

对于第 t 帧，机器人正向运动学可表示为

$$\mathbf{x}_{i,t}^r = F_i^R(\mathbf{p}_t^r, \mathbf{R}_t^r, \mathbf{q}_t^r), \quad (3-8)$$

其中 $F_i^R(\cdot)$ 为机器人第 i 个匹配连杆参考点的正向运动学函数， $\mathbf{p}_t^r$ 为机器人根节点位置， $\mathbf{R}_t^r$ 为根节点旋转， $\mathbf{q}_t^r$ 为机器人关节角。

逐帧重定向的核心目标是最小化机器人关键点与清洗后人体关键点之间的空间误差：

$$\mathcal{L}_{kp} = \frac{1}{|I|} \sum_{i \in I} w_i \left\| F_i^R(\mathbf{p}_t^r, \mathbf{R}_t^r, \mathbf{q}_t^r) - \mathbf{x}_{i,t}^h \right\|_2^2. \quad (3-9)$$

该项约束机器人在空间中的身体形态接近人体参考动作。由于机器人和人体自由度不同，该误差通常无法降为零，因此重定向追求的是关键部位运动趋势一致，而不是完全复制人体骨骼姿态。

仅依赖关键点距离会导致相邻帧之间出现抖动，因此本文加入时间平滑项：

$$\mathcal{L}_{smooth} = \left\| \mathbf{q}_t^r - \mathbf{q}_{t-1}^r \right\|_2^2 + \eta \left\| (\mathbf{q}_t^r - \mathbf{q}_{t-1}^r) - (\mathbf{q}_{t-1}^r - \mathbf{q}_{t-2}^r) \right\|_2^2. \quad (3-10)$$

第一项限制关节角的一阶变化幅度，第二项限制关节角加速度形式的二阶变化， η 为二阶平滑权重。该设计可以减少高频噪声，并使后续 PD 控制器更容易跟踪参考轨迹。

同时，为避免优化结果过度接近关节极限，本文引入关节限位惩罚项：

$$\mathcal{L}_{limit} = \sum_{d=1}^{n_q} \left[\max(0, q_{t,d}^r - q_d^{\max})^2 + \max(0, q_d^{\min} - q_{t,d}^r)^2 \right], \quad (3-11)$$

其中 n_q 为机器人可控关节数， $q_d^{\min}$ 和 $q_d^{\max}$ 分别为第 d 个关节的机械下限和上限。该项在关节位于合法范围内时为零，只有当优化结果越界时才产生惩罚。

综合上述约束，第 t 帧的重定向优化问题写为

$$\min_{\mathbf{p}_t^r, \mathbf{R}_t^r, \mathbf{q}_t^r} \mathcal{L}_{\text{retarget}} = \mathcal{L}_{\text{kp}} + \lambda_s \mathcal{L}_{\text{smooth}} + \lambda_l \mathcal{L}_{\text{limit}}, \quad (3-12)$$

其中 λ_s 和 λ_l 分别控制时间平滑和关节限位约束的权重。式 (3-12) 中的三类误差具有不同作用：关键点误差保证动作语义，平滑误差保证轨迹连续，限位误差保证机器人结构可达。

在实现中，本文采用分组优化策略：根节点平移和旋转属于低维全局变量，主要影响机器人整体位置；关节角属于高维局部变量，主要影响肢体姿态。将两类变量分别设置学习率并交替更新，可以降低根位姿误差和肢体姿态误差之间的相互干扰。每轮更新后，还依据统一机器人描述格式 (Unified Robot Description Format, URDF) 或 MuJoCo XML 格式 (MuJoCo XML Format, MJCF) 中的关节范围执行截断：

$$\mathbf{q}_t^r \leftarrow \text{clip}(\mathbf{q}_t^r, \mathbf{q}_{\min}, \mathbf{q}_{\max}). \quad (3-13)$$

该操作相当于将优化结果投影回机器人可行关节空间，能够减少穿模、自碰撞和非物理构型。

3.6 轨迹平滑、接触修正与数据封装




图 3-5 专家轨迹封装调用方式示意图

逐帧优化后的机器人轨迹仍可能包含小幅抖动。为了增强时间连续性，本

文对关节角、根节点平移和根节点旋转进行后处理。对关节角序列，采用一维高斯滤波：

$$\tilde{\mathbf{q}}_t^r = \sum_{k=-K}^K G_\sigma(k) \mathbf{q}_{t-k}^r, \quad G_\sigma(k) = \frac{\exp\left(-\frac{k^2}{2\sigma^2}\right)}{\sum_{m=-K}^K \exp\left(-\frac{m^2}{2\sigma^2}\right)}. \quad (3-14)$$

其中 $G_\sigma(k)$ 为归一化高斯核， σ 控制平滑强度， K 为滤波窗口半径。归一化分母保证所有权重之和为 1，因此滤波后不会系统性改变关节角均值。根节点平移采用同样的滤波形式，根节点旋转则先转换为连续旋转表示或四元数，再进行插值和平滑，避免旋转角度跳变。

由于人体数据缺少真实接触力信息，重定向轨迹可能出现足端略微离地或插入地面的情况。本文根据机器人足端关键点高度进行整体高度修正。设 $\mathcal{F}$ 为足端关键点集合，重定向后第 t 帧足端最低高度为

$$h_t = \min_{j \in \mathcal{F}} z_{j,t}^r, \quad (3-15)$$

其中 $z_{j,t}^r$ 表示第 j 个足端关键点的竖直坐标。若地面高度设为 0，则可将根节点高度修正为

$$\tilde{\mathbf{p}}_t^r = \mathbf{p}_t^r - [0, 0, h_t - h_{\text{margin}}]^T, \quad (3-16)$$

其中 h_{margin} 为预留的足底高度裕量。该修正使轨迹整体与地面保持合理接触关系，降低强化学习环境初始化时的异常碰撞风险。

最终，本文将处理后的数据封装为统一的动作文件，主要字段包括根节点平移 $\tilde{\mathbf{p}}_t^r$ 、根节点旋转 $\tilde{\mathbf{R}}_t^r$ 、关节角 $\tilde{\mathbf{q}}_t^r$ 、关节速度 $\tilde{\mathbf{q}}_t^r$ 、刚体关键点状态 $\mathcal{X}_t^r$ 、帧率和动作元数据。在强化学习训练阶段，动作库模块根据当前相位 $\phi \in [0, 1]$ 查询或插值得到参考状态。若动作长度为 T 帧，则相位与帧索引的对应关系可写为

$$u(\phi) = 1 + \phi(T - 1). \quad (3-17)$$

当 $u(\phi)$ 不是整数时，平移和关节角采用相邻帧线性插值，旋转采用球面线性插值。这样可以在仿真控制频率与数据原始帧率不一致时，仍然获得连续的参考状态。

3.7 本章小结

本章围绕专家数据预处理与动作重定向展开说明。首先，本章将 AMASS

或视频重建得到的人体动作统一表示为 SMPL 运动序列，并进行坐标规范化和时间重采样；其次，通过人体关键点与机器人连杆关键点之间的拓扑映射，建立跨结构动作转换关系；随后，利用体型拟合、仿真清洗、关键点误差优化、时间平滑和关节限位约束，将人体专家动作转换为机器人可执行参考轨迹；最后，将轨迹封装为强化学习环境可直接调用的动作库文件。经过上述处理，原始人体动作从仅具备运动学意义的数字，转化为兼顾机器人结构可达性和物理跟踪可行性的专家参考，为后续的强化学习运动跟踪方法提供基础。

第4章 基于强化学习的运动跟踪方法

在获得机器人可执行的参考动作轨迹之后，下一步需要解决的问题是如何在物理仿真环境中学习稳定、自然且具备一定鲁棒性的整身动作跟踪策略。与单纯的运动学模仿不同，强化学习动作跟踪需要同时考虑接触切换、执行器约束、整体平衡和长时序控制误差累积等因素，因此必须对任务建模、观测表示、动作输出、奖励函数和训练机制进行系统设计。基于这一目标，本章将围绕整身动作跟踪任务架构、相位建模、非对称 Actor-Critic、PPO 优化目标以及稳定化训练策略展开详细说明。

4.1 任务建模、观测空间与相位建模

在完成专家数据预处理后，本文基于 HumanoidVerse 风格的并行强化学习框架构建整身动作跟踪任务。该任务以第3章生成的机器人参考轨迹为目标输入，在 Isaac Gym 物理仿真环境中通过大量并行环境采样，实现从机器人当前状态到关节控制指令的闭环映射。整体方法可概括为“参考轨迹查询 - 状态编码 - 策略输出 - 低层控制 - 奖励反馈”五个环节。

在每一个控制周期内，动作库模块根据当前动作编号和相位变量查询参考状态；环境模块将机器人本体感知信息与参考动作时序信息组合为观测向量；策略网络输出连续动作；底层 PD 控制器将该动作转换为关节驱动力矩；仿真器进一步完成动力学积分，并根据机器人状态与参考状态之间的误差计算奖励信号，最终用于更新策略参数。该流程与 DeepMimic 中“以参考动作约束物理仿真探索”的思想一致^[17]，但针对人形机器人高自由度、多接触和长时序动作跟踪问题做了更适合机器人控制的任务建模。

本文没有采用直接最小化专家动作与策略动作差异的行为克隆方法，而是采用基于强化学习的模仿学习范式。原因在于，人形机器人动作执行过程受到接触切换、执行器响应、关节限位和整体平衡约束的共同影响，仅凭监督学习很难保证动作在物理环境中的可行性。强化学习通过最大化长期累计回报，使策略在跟踪参考动作的同时主动适应动力学约束，从而获得更高的运动稳定性和动作自然度。

为了使策略既能感知机器人自身动态状态，又能识别当前所处的参考动作




图 4-1 基于强化学习的整身动作跟踪总体框架

阶段，本文将观测表示为相位条件状态：

$$s_t = [s_t^p, \phi_t], \quad (4-1)$$

其中 s_t^p 表示机器人本体感知状态， $\phi_t \in [0, 1]$ 表示归一化动作相位。该设计继承了相位驱动动作模仿的基本思想^[17]，使得单个策略能够沿参考动作时间轴学习不同阶段的控制模式。

对于本体感知状态，本文采用短历史堆叠形式增强策略对速度和动态趋势的辨识能力。设机器人有 n_q 个可控关节， $q_t \in \mathbb{R}^{n_q}$ 和 $\dot{q}_t \in \mathbb{R}^{n_q}$ 分别表示当前关节角与关节角速度， $\omega_t^{\text{root}} \in \mathbb{R}^3$ 表示根节点角速度， $g_t^{\text{root}} \in \mathbb{R}^3$ 表示投影到根节点坐标系下的重力方向， $a_{t-1} \in \mathbb{R}^{n_q}$ 表示上一步策略输出动作，则本体感知状态写为

$$s_t^p \triangleq [q_{t-h+1:t}, \dot{q}_{t-h+1:t}, \omega_{t-h+1:t}^{\text{root}}, g_{t-h+1:t}^{\text{root}}, a_{t-1}], \quad (4-2)$$

其中 h 为历史步长。使用短时历史而不是单帧状态，有助于策略在不显式构建系统模型的情况下隐式估计关节运动趋势和姿态变化。

相位变量用于描述当前时刻在参考动作中的归一化位置。设当前参考动作总时长为 T_{motion} ，动作起始时刻为 t_{start} ，则相位定义为

$$\phi_t = \frac{t - t_{\text{start}}}{T_{\text{motion}}}. \quad (4-3)$$

当 $\phi_t = 0$ 时表示动作刚开始， $\phi_t = 1$ 时表示动作结束。对于周期性动作，还可采用取模方式将相位约束在一个周期内。该变量能够帮助策略区分同一动作中“起跳、腾空、落地”或“下蹲、发力、恢复”等不同阶段。

动作空间采用连续关节目标表示。设策略输出为

$$a_t = \pi_\theta(s_t) \in \mathbb{R}^{n_q}, \quad (4-4)$$

则该动作经过缩放或偏置映射后生成关节目标位置 q_t^* 。在工程实现中，可写为

$$q_t^* = q_t^{\text{ref}} + \alpha \odot a_t, \quad (4-5)$$

其中 q_t^{ref} 为参考关节角， α 为动作缩放系数， $\odot$ 表示逐元素乘法。该形式表明策略不必从零开始生成完整关节目标，而是在参考动作附近学习更适合当前动力学环境的控制修正量。

4.2 策略结构与仿真闭环

人形机器人动作跟踪本质上可以建模为部分可观测马尔可夫决策过程。虽然仿真环境可以直接访问全局刚体位置、参考轨迹未来片段和根节点线速度等信息，但这些量在真实部署或统一控制接口下通常不容易直接获得。因此，本文采用非对称 Actor-Critic 训练框架：Actor 仅依赖本体感知和相位变量，Critic 在训练过程中额外访问更丰富的特权信息，以提升价值估计质量。

Actor 输入定义为

$$s_t^A = [s_t^p, \phi_t], \quad (4-6)$$

Critic 输入定义为

$$s_t^C = [s_t^A, \hat{x}_t^{\text{ref}}, \hat{v}_t^{\text{ref}}, \hat{x}_t^{\text{sim}}], \quad (4-7)$$

其中 $\hat{x}_t^{\text{ref}}$ 表示参考动作的关键刚体位置特征， $\hat{v}_t^{\text{ref}}$ 表示参考根速度或刚体速度特征， $\hat{x}_t^{\text{sim}}$ 表示仿真环境中额外可获得的辅助状态。该设计的作用在于：Actor 侧保留未来可部署的紧凑输入形式，而 Critic 侧借助特权状态提供更稳定的优势估计和价值学习。

设 Actor 参数为 θ ，Critic 参数为 ψ ，则策略分布和价值函数分别写为

$$\pi_\theta(a_t | s_t^A), \quad V_\psi(s_t^C). \quad (4-8)$$

在训练时，Critic 利用更完整的环境状态拟合回报，而 Actor 只根据自身可观测输入更新参数。该结构在动作跟踪任务中能够显著缓解仅用局部状态时的学习不稳定问题，也为后续 sim-to-sim 或 sim-to-real 迁移保留更一致的输入接口。




图 4-2 非对称 Actor-Critic 训练结构示意图

策略网络输出的连续动作并不直接作为电机力矩施加到机器人关节上，而是通过低层 PD 控制器转换为物理上更平滑的关节驱动信号。设当前关节状态为 $(q_t, \dot{q}_t)$ ，目标关节状态为 $(q_t^*, \dot{q}_t^*)$ ，则第 t 步控制力矩写为

$$\tau_t = K_p (q_t^* - q_t) + K_d (\dot{q}_t^* - \dot{q}_t), \quad (4-9)$$

其中 K_p 和 K_d 分别为比例增益和微分增益矩阵。通常情况下， $\dot{q}_t^*$ 可设为参考关节速度或零向量。

将 PD 控制器、机器人动力学与接触模型统一记为环境转移函数 f^{sim} ，则闭环系统动态可写为

$$s_{t+1} = f^{\text{sim}}(s_t, \tau_t, \xi_t), \quad (4-10)$$

其中 ξ_t 表示地面摩擦、质量扰动、传感器噪声和接触求解误差等环境因素。该表达式说明强化学习任务并不是直接学习解析动力学，而是在仿真环境隐式定义的状态转移过程中学习长期最优控制策略。

与直接输出力矩相比，基于位置目标和 PD 控制的方式更适合利用参考轨

迹中的运动学先验。策略只需要学习在参考轨迹基础上的控制偏置，而不必同时学习关节期望位置和电机响应规律，因而通常更易训练，也更符合现有人形机器人控制接口的工程实现方式。

4.3 优化目标与奖励设计

设策略网络为 $\pi_\theta(a_t|s_t^A)$ ，其中 θ 为网络参数，则全身动作跟踪任务的优化目标是最大化折扣累计回报：

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \gamma^t r_t \right], \quad (4-11)$$

其中 $\tau = (s_0, a_0, s_1, a_1, \dots)$ 为策略采样得到的轨迹， γ 为折扣因子， r_t 为由模仿奖励和正则项共同构成的即时回报。

本文采用近端策略优化算法（PPO）更新策略参数^[8]。设

$$\rho_t(\theta) = \frac{\pi_\theta(a_t|s_t^A)}{\pi_{\theta_{\text{old}}}(a_t|s_t^A)} \quad (4-12)$$

为新旧策略概率比， $\hat{A}_t$ 为优势函数估计，则 PPO 的截断替代目标为

$$\mathcal{L}^{\text{clip}}(\theta) = \mathbb{E}_t \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]. \quad (4-13)$$

再综合价值函数误差项和策略熵正则项，训练目标可写为

$$\mathcal{L}_{\text{PPO}}(\theta, \psi) = \mathbb{E}_t \left[\mathcal{L}^{\text{clip}}(\theta) - c_v (V_\psi(s_t^C) - \hat{R}_t)^2 + c_e \mathcal{H}(\pi_\theta(\cdot|s_t^A)) \right], \quad (4-14)$$

其中 V_ψ 为价值网络输出， $\hat{R}_t$ 为回报估计， $\mathcal{H}$ 表示策略熵， c_v 和 c_e 分别为价值损失权重和熵正则权重。熵项能够抑制训练早期过快收缩到单一动作模式，从而提升探索能力。

4.3.1 参考状态表示与误差度量

在动作跟踪任务中，奖励和评价都需要建立在机器人当前状态与参考轨迹状态之间的误差度量上。设第 i 个刚体在仿真状态与参考状态中的空间位置分别为 $x_i^{\text{sim}}(t)$ 和 $x_i^{\text{ref}}(t)$ ，则其位置误差为

$$\Delta x_i(t) = x_i^{\text{sim}}(t) - x_i^{\text{ref}}(t). \quad (4-15)$$

刚体姿态采用四元数表示，其相对姿态误差写为

$$q_i^{\text{err}}(t) = q_i^{\text{sim}}(t) \otimes (q_i^{\text{ref}}(t))^{-1}, \quad (4-16)$$

其中 $\otimes$ 表示四元数乘法。线速度和角速度误差分别定义为

$$\Delta v_i(t) = v_i^{\text{sim}}(t) - v_i^{\text{ref}}(t), \quad \Delta \omega_i(t) = \omega_i^{\text{sim}}(t) - \omega_i^{\text{ref}}(t). \quad (4-17)$$

在关节空间中，关节角和关节角速度误差表示为

$$\Delta q(t) = q^{\text{sim}}(t) - q^{\text{ref}}(t), \quad \Delta \dot{q}(t) = \dot{q}^{\text{sim}}(t) - \dot{q}^{\text{ref}}(t). \quad (4-18)$$

为了减少全局平移和航向角对跟踪误差的直接干扰，位置类误差在送入策略或奖励前通常会转换到根节点局部坐标系中。设 $R_{\text{heading}}(q_{\text{root}}^{\text{ref}}(t))$ 表示由参考根姿态提取出的偏航旋转矩阵，则局部位置误差为

$$\Delta \hat{x}_i(t) = R_{\text{heading}}^{-1}(q_{\text{root}}^{\text{ref}}(t)) \Delta x_i(t). \quad (4-19)$$

该操作能够让策略更关注身体各部位之间的相对构型，而不是仅通过记忆全局轨迹来完成控制。

4.3.2 奖励函数设计

本文的奖励函数围绕参考动作与机器人当前状态之间的多模态误差构建。在具体实现中，奖励由动作跟踪奖励、正则化惩罚项和终止惩罚三部分组成，其总体形式可写为

$$r_t = \sum_{k \in \mathcal{M}} w_k r_k^{\text{track}}(t) + \lambda_p \sum_{j \in \mathcal{R}} w_j r_j^{\text{pen}}(t) + w_{\text{term}} r_{\text{term}}(t), \quad (4-20)$$

其中 $\mathcal{M}$ 为动作跟踪奖励集合， $\mathcal{R}$ 为惩罚项集合， w_k 、 w_j 和 w_{term} 为对应权重， λ_p 为惩罚项课程学习系数。本文实际训练中， λ_p 用于调节力矩、动作变化率、关节约束、足部姿态和足端滑移等惩罚项的影响强度，使策略在训练早期能够优先学会基本跟踪能力，在训练后期再逐步强化物理可实现性与动作质量约束。

在动作跟踪部分，本文并非只对单一姿态误差进行奖励，而是同时约束全身关键刚体位置、遥操作三点位置、双脚位置、全身刚体旋转、刚体线速度、刚体角速度、关节角以及关节速度等多种信息。对这些跟踪项，本文统一采用指数核形式将误差映射到 $(0, 1]$ 范围内。以全身刚体位置奖励为例，考虑到上半身和下半身对动作自然性的贡献不同，本文分别计算其位置误差并进行加权：

$$r_{\text{body_pos}}(t) = \alpha_{\text{low}} \exp\left(-\frac{\mathbb{E}_{i \in \mathcal{B}_{\text{low}}} [\|\Delta x_i(t)\|_2^2]}{\sigma_{\text{low}}}\right) + \alpha_{\text{up}} \exp\left(-\frac{\mathbb{E}_{i \in \mathcal{B}_{\text{up}}} [\|\Delta x_i(t)\|_2^2]}{\sigma_{\text{up}}}\right), \quad (4-21)$$

$$r_{\text{vr3}}(t) = \exp\left(-\frac{\mathbb{E}_{i \in \mathcal{V}} [\|\Delta x_i(t)\|_2^2]}{\sigma_{\text{vr3}}}\right), \quad (4-22)$$

$$r_{\text{feet}}(t) = \exp\left(-\frac{\mathbb{E}_{i \in \mathcal{F}} [\|\Delta x_i(t)\|_2^2]}{\sigma_{\text{feet}}}\right), \quad (4-23)$$

$$r_{\text{body_rot}}(t) = \exp\left(-\frac{\mathbb{E}_i [\|\Delta \theta_i(t)\|_2^2]}{\sigma_{\text{rot}}}\right), \quad (4-24)$$

$$r_{\text{body_vel}}(t) = \exp\left(-\frac{\mathbb{E}_i [\|\Delta v_i(t)\|_2^2]}{\sigma_{\text{vel}}}\right), \quad (4-25)$$

$$r_{\text{body_angvel}}(t) = \exp\left(-\frac{\mathbb{E}_i [\|\Delta \omega_i(t)\|_2^2]}{\sigma_{\text{angvel}}}\right), \quad (4-26)$$

$$r_{\text{joint_pos}}(t) = \exp\left(-\frac{\mathbb{E}_m [(\Delta q_m(t))^2]}{\sigma_{\text{joint_pos}}}\right), \quad (4-27)$$

$$r_{\text{joint_vel}}(t) = \exp\left(-\frac{\mathbb{E}_m [(\Delta \dot{q}_m(t))^2]}{\sigma_{\text{joint_vel}}}\right). \quad (4-28)$$

上述奖励项分别对应“上半身与下半身关键点位置对齐”“遥操作关键观测点对齐”“双脚落点对齐”“全身姿态一致”“全身速度一致”“关节姿态接近参考”和“关节速度变化规律接近参考”等目标。指数核的优点在于：误差较小时奖励变化细腻，有利于后期精调；误差较大时奖励迅速衰减，有助于将策略搜索限制在参考动作附近，从而提升训练稳定性。

除跟踪奖励外，本文还加入控制平滑性与物理约束相关的惩罚项，以抑制不合理控制策略。对动作变化率和关节力矩，可分别定义

$$r_{\text{action_smooth}}(t) = -\|a_t - a_{t-1}\|_2^2, \quad (4-29)$$

对关节力矩幅值可定义

$$r_{\text{torque}}(t) = -\|\tau_t\|_2^2, \quad (4-30)$$

此外，本文实际训练中还显式加入了关节位置越界惩罚、关节速度越界惩罚、

力矩接近饱和惩罚、足部姿态惩罚、双脚朝向偏差惩罚以及接触状态下的足端滑移惩罚。上述惩罚项共同约束策略在完成动作模仿的同时保持平滑、节能并满足基本接触物理规律。进一步地，当机器人在训练过程中偏离参考动作过大并触发回合终止时，还会施加额外的终止惩罚，用于抑制明显失稳或动作崩坏的行为。




图 4-3 动作跟踪任务奖励函数组成示意图

4.4 稳定化机制与数据回收

高动态动作训练往往容易在早期发生频繁摔倒或陷入局部最优。为此，本文在任务设计中引入终止课程学习、参考状态初始化和域随机化三类稳定化机制，这些设计参考了物理角色动作模仿和机器人学习控制中的常见经验^[17,23-24]。

4.4.1 终止课程学习

当机器人偏离参考动作过大时，继续滚动当前轨迹通常只会产生低质量样本。为此，本文设置动作偏离终止条件：若机器人关键点平均误差超过阈值 τ_k ，则提前结束当前回合并重置环境，

$$\frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \|\Delta x_i(t)\|_2 > \tau_k \Rightarrow \text{reset}, \quad (4-31)$$

其中 $\mathcal{B}$ 为关键刚体集合， τ_k 为第 k 个训练阶段对应的误差阈值。

训练初期，阈值设置得较宽，允许策略在较大误差范围内探索；随着训练推进，再逐步收紧阈值。其课程调度形式可写为

$$\tau_k = \tau_{\max} - \min\left(\frac{k}{K}, 1\right)(\tau_{\max} - \tau_{\min}), \quad (4-32)$$

其中 $\tau_{\max}$ 和 $\tau_{\min}$ 分别为课程开始和结束时的误差容忍度， K 为课程总阶段数。该机制使策略先学会基本平衡，再逐步提高模仿精度。

4.4.2 参考状态初始化

若每个回合都从动作第一帧开始训练，长序列动作的后半段将较难被充分采样。为此，本文采用参考状态初始化 (Reference State Initialization, RSI) 机制^[17]。具体地，在回合开始时随机采样初始相位

$$\phi_0 \sim \mathcal{U}(0, 1), \quad (4-33)$$

再根据相位映射到参考轨迹帧索引

$$t_0 = \lfloor \phi_0(T - 1) \rfloor, \quad (4-34)$$

并使用第 t_0 帧对应的根位姿、关节角和关节速度初始化机器人状态。该机制可以显著提升策略对中间关键动作片段的学习效率，特别适用于腾空、落地和快速转向等高动态动作。

4.4.3 域随机化与训练鲁棒性

为了提升策略对动力学参数扰动和传感噪声的适应能力，本文在训练阶段对部分环境参数进行随机化处理。设随机化参数集合为

$$\xi \sim p(\xi), \quad (4-35)$$

则环境转移可改写为

$$s_{t+1} = f^{\text{sim}}(s_t, \tau_t; \xi), \quad (4-36)$$

其中 ξ 可包含连杆质量扰动、摩擦系数、控制延迟、观测噪声和外部推力等因素。域随机化不会替代主任务奖励，而是通过在训练阶段扩大环境分布，提高策略在不同场景中的泛化能力。

4.4.4 轨迹闭环与数据回收

当策略训练逐渐收敛后，可以对闭环执行过程进行轨迹采集，记录机器人状态、策略动作和运动学参量，并将其重新封装为标准化轨迹文件。该过程相当于在原始专家轨迹之外，再生成一批经过物理环境约束修正后的闭环执行轨迹。记闭环采集得到的数据为

$$\mathcal{D}_{\text{loop}} = \{s_t, a_t, \tau_t, \mathcal{X}_t\}_{t=1}^T, \quad (4-37)$$

则其既可用于后续离线分析，也可作为补充轨迹帮助检查原始参考动作与真实闭环执行之间的偏差。该机制对于分析动作失败原因、观察落地缓冲行为和优化奖励权重具有重要作用。

4.5 本章小结

本章围绕基于强化学习的人形机器人动作跟踪方法展开。首先，本文构建了相位条件状态表示，将本体感知信息与动作相位共同作为策略输入；其次，利用非对称 Actor-Critic 结构和 PPO 算法实现稳定训练，并通过 PD 控制器将策略输出映射为可执行关节控制信号；然后，围绕刚体位置、根姿态、关节角和关节速度设计多模态模仿奖励，并加入动作平滑和力矩惩罚项保证训练稳定性；最后，引入终止课程学习、参考状态初始化和域随机化等机制，提高高动态动作学习效率和策略泛化能力。这些设计共同构成了本文动作跟踪方法的核心，为下一章实验设计与结果分析提供方法基础。

第 5 章 实验设计与结果分析

在前两章分别完成专家数据处理与强化学习动作跟踪方法设计之后，本章的任务是通过系统实验验证所提方法的有效性，并分析策略在不同动作类型和不同测试条件下的实际表现。由于本文当前工作主要聚焦于仿真环境中的人形机器人运动技能学习，因此实验部分将重点围绕动作跟踪精度、训练稳定性、鲁棒性和泛化性开展，对参考轨迹质量、奖励设计、训练机制以及抗扰表现进行系统评估，从而检验前述方法在典型运动任务中的实际效果。

5.1 实验设置与评价方法

为了验证本文提出的专家数据预处理与强化学习动作跟踪方法的有效性，本章从动作跟踪精度、训练稳定性、鲁棒性和泛化性四个方面开展实验分析。实验的核心目标包括：第一，验证所构建的参考轨迹能否支持机器人稳定学习目标动作；第二，评估所设计的奖励函数与稳定化机制是否能提升动作跟踪质量；第三，观察策略在扰动、噪声和环境变化条件下的表现。

考虑到本文当前研究重点主要放在仿真环境中的运动学习与方法验证，因此实验章节以高保真物理仿真测试为主。实验任务覆盖了 CR7、jump forward、walk、single foot balance、play the violin 和 play basketball 六类具有代表性的全身动作场景，既包含对身体平衡性要求较高的静态或准静态动作，也包含对关节协调性、节奏性和动态跟踪能力要求更高的快速动作。

实验平台与参数设置

本文实验基于 Isaac Gym 仿真平台搭建动作跟踪环境^[5]。机器人模型由 URDF 或 MJCF 文件描述，环境中配置了关节驱动参数、接触碰撞模型、地面摩擦参数和批量并行训练接口。实验中所用参考轨迹来源于第 3 章得到的机器人动作库，训练算法采用第 4 章所述 PPO 优化目标和非对称 Actor-Critic 网络结构。

在训练设置上，本文给定并记录了并行环境数量、控制频率、策略更新周期、折扣因子、学习率、PPO 截断系数以及广义优势估计（Generalized Advantage Estimation, GAE）系数等超参数。相关训练参数如表 5-1 所示。

评价指标

表 5-1 强化学习训练关键超参数设置

参数名称	取值或说明
仿真平台	Isaac Gym
并行环境数量	4096
仿真频率 / 仿真步长	200 Hz / 0.005 s
控制频率 / 控制周期	50 Hz / 0.02 s
控制降采样系数	4
PPO 学习率	1×10^{-3}
折扣因子 γ	0.99
GAE 系数 λ	0.95
截断系数 ϵ	0.2
PPO 更新轮数	5
mini-batch 数量	4
每环境 rollout 步长	24
单次更新样本数	98304
历史观测步长 h	4 帧
最大回合时长	20 s
训练总迭代轮数	1000000
模型保存间隔	100
域随机化	False
动作重采样	False
终止条件课程学习	True
终止距离阈值最小值	0.3
终止课程学习系数	2.5×10^{-5}
奖励惩罚课程学习	True
奖励惩罚课程学习系数	1×10^{-5}
自碰撞设置	0
控制器类型	P
动作缩放系数	0.25

为全面评估动作跟踪效果，本文采用位置误差、姿态误差、速度误差和任务成功率等指标。设测试集中共有 N 段动作，每段动作长度为 T ，第 i 个关键点在第 t 帧的仿真位置与参考位置分别为 $\hat{x}_{i,t}$ 和 $x_{i,t}$ ，则全局平均关键点位置误差可表示为

$$E_{\text{g-mpjpe}} = \frac{1}{NT|\mathcal{B}|} \sum_{n=1}^N \sum_{t=1}^T \sum_{i \in \mathcal{B}} \|\hat{x}_{i,t} - x_{i,t}\|_2, \quad (5-1)$$

其中 $\mathcal{B}$ 为用于评估的关键刚体集合。

若在消除根节点平移影响后再计算各关键点误差，则得到根相对平均关节位置误差：

$$E_{\text{mpjpe}} = \frac{1}{NT|\mathcal{B}|} \sum_{n=1}^N \sum_{t=1}^T \sum_{i \in \mathcal{B}} \|(\hat{x}_{i,t} - \hat{x}_{\text{root},t}) - (x_{i,t} - x_{\text{root},t})\|_2. \quad (5-2)$$

此外，还可分别统计速度误差与加速度误差：

$$E_{\text{vel}} = \frac{1}{NT} \sum_{n=1}^N \sum_{t=1}^T \|\hat{v}_t - v_t\|_2, \quad E_{\text{acc}} = \frac{1}{NT} \sum_{n=1}^N \sum_{t=1}^T \|\hat{a}_t - a_t\|_2. \quad (5-3)$$

若将成功完成整段动作定义为“回合内未发生提前终止，且平均关键点误差始终低于给定阈值”，则成功率可定义为

$$\text{SR} = \frac{1}{N} \sum_{n=1}^N \mathbb{I}(\text{episode } n \text{ success}), \quad (5-4)$$

其中 $\mathbb{I}(\cdot)$ 为示性函数。上述指标分别从“空间位置对齐”“局部姿态精度”“运动学连续性”和“任务完成稳定性”四个角度评价策略性能。

5.2 主要实验结果与案例分析

首先，对本文方法在六类代表性动作上的主实验结果进行统计。实验结果按照“动作类别 - 关键指标”的形式整理，如表 5-2 所示。整体来看，低动态和周期性动作通常更容易获得较低误差，而腾空、落地和快速上肢摆动较多的复杂动作对策略稳定性提出了更高要求。

从表 5-2 可以看出，walk 与 single foot balance 的跟踪误差最低，说明对于周期性较强或以平衡保持为主的动作，所构建的参考轨迹和强化学习策略能够较好地完成稳定复现。相比之下，jump forward 与 play basketball 的全局位置误差和速度误差更大，成功率也相对较低，这主要与动作中存在明显腾空、落地冲击以及快速重心转移有关。CR7 和 play the violin 的整体表现处于中间水平，表

表 5-2 主要动作跟踪实验结果

动作名称	$E_{g\text{-mpjpe}}$	E_{mpjpe}	E_{vel}	E_{acc}	成功率
CR7	0.102	0.071	0.189	0.842	91.3%
jump forward	0.136	0.094	0.248	1.126	84.7%
walk	0.061	0.038	0.112	0.487	97.8%
single foot balance	0.074	0.046	0.095	0.421	96.1%
play the violin	0.089	0.057	0.143	0.638	93.5%
play basketball	0.128	0.086	0.231	1.034	86.9%

明对于包含上肢大幅摆动和全身节奏变化的动作，策略已经能够学习到主要运动模式，但在局部细节还存在进一步优化空间。整体而言，成功率与位置误差、速度误差的变化趋势基本一致，说明误差指标能够较好反映动作是否被稳定完成。

为了进一步说明本文方法相对于若干基础方案的优势，本文将代表性方法的结果整理如表 5-3 所示。

表 5-3 不同方法或不同配置下的动作跟踪对比结果

方法	$E_{g\text{-mpjpe}}$	E_{mpjpe}	E_{vel}	E_{acc}	成功率
本文方法	0.098	0.065	0.170	0.758	91.7%
开环 PD 参考跟踪	0.186	0.129	0.346	1.684	62.4%
仅关节角参考跟踪	0.154	0.101	0.284	1.327	74.1%
基础 PPO 跟踪	0.123	0.081	0.216	0.986	85.2%
监督学习策略基线	0.141	0.093	0.257	1.145	79.6%

从表 5-3 可以看出，开环 PD 跟踪虽然能够在短时间内逼近部分参考姿态，但在接触切换和动态平衡环节容易出现误差累积，因此整体成功率最低。仅关节角参考跟踪忽略了关键刚体位置和速度信息，对全身协调性的约束较弱。基础 PPO 跟踪相较传统方法已有明显改善，但在高动态动作上仍容易出现动作发散。相比之下，本文方法在各项误差指标和成功率上均取得最优结果，说明多模态参考约束与稳定化训练机制对提升全身动作跟踪质量是有效的。

案例分析与动作可视化

除表格中的误差与成功率指标外，动作可视化结果同样是验证方法有效性的重要证据。通过展示机器人在关键时间步上的姿态变化，可以更加直观地观察动作是否自然、重心是否稳定、落地是否平顺以及上肢与下肢是否协同。图 5-1 给出了代表性动作的可视化结果，其中深蓝色背景为 Mujoco 中经过数据预处理后得到的标准动作，灰色背景为 Isaac Gym 中训练得到的跟踪动作，黄色点表示用于动作跟踪与误差计算的参考关键点。通过该图可以进一步观察参考动

作与机器人执行结果在关键姿态、肢体摆动幅度以及整体节奏上的一致性。

除最终动作表现外，训练过程中的关键统计量也能够反映策略是如何逐步学会稳定跟踪参考动作的。图 5-2 和图 5-3 给出了训练过程中 8 类具有代表性的 TensorBoard 曲线，包括平均回报、平均回合长度、全身关键刚体位置跟踪奖励、关节角跟踪奖励、动作变化率惩罚、上半身关键点误差范数、关节角误差范数以及惩罚课程学习系数。可以看到，随着训练进行，平均回报与平均回合长度整体呈上升趋势，说明策略逐渐减少提前终止并获得更稳定的动作执行能力；与此同时，刚体位置奖励和关节角奖励逐步提升，而上半身误差与关节角误差整体下降，表明机器人在全身姿态和局部关节层面都在持续逼近参考轨迹。动作变化率惩罚在训练后期趋于稳定，说明控制输出逐步变得平滑；惩罚课程学习系数则反映了训练过程中对安全约束强度的逐步调节，使策略能够先学习基本模仿能力，再进一步兼顾动作平滑性与物理合理性。

综合图 5-1 与图 5-2 和图 5-3 可以看出，本文方法不仅在最终动作形态上能够较好地复现参考动作，而且在训练过程中也表现出较清晰的收敛趋势。前者说明策略学到的动作具有较好的视觉自然性和全身协调性，后者则从优化过程层面进一步验证了奖励设计与课程机制对训练稳定性的积极作用。

5.3 鲁棒性与泛化实验

为了检验策略是否不仅在标准环境下有效，而且能够在环境发生扰动时保持动作质量，本文进一步设计鲁棒性与泛化测试。测试因素包括外部推力干扰、观测噪声、控制延迟以及跨场景配置变化。实验结果按测试场景分类整理，如表 5-4 所示。

表 5-4 鲁棒性与泛化实验结果

测试场景	$E_{g-mpjpe}$	E_{mpjpe}	E_{vel}	E_{acc}	成功率
标准环境	0.098	0.065	0.170	0.758	91.7%
外部推力扰动	0.114	0.077	0.198	0.873	88.4%
观测噪声	0.109	0.073	0.191	0.826	89.2%
控制延迟	0.121	0.082	0.214	0.952	86.1%
跨场景 / 跨仿真器测试	0.132	0.089	0.227	1.031	83.5%

表 5-4 表明，策略在标准环境下取得了最优表现；加入外部推力和观测噪声后，各项误差略有上升，但整体成功率仍保持在较高水平，说明策略已具备一定抗扰能力。控制延迟和跨场景测试带来的性能下降更为明显，这反映出时

序误差累积和动力学失配仍然是影响动作跟踪泛化能力的关键因素。不过，即使在更严格的测试条件下，策略仍能维持 80% 以上的成功率，说明本文方法具有较好的鲁棒性基础。




图 5-1 代表性动作的可视化结果




图 5-2 训练过程中关键 TensorBoard 指标变化曲线 1




图 5-3 训练过程中关键 TensorBoard 指标变化曲线 2

第 6 章 总结与展望

6.1 结果讨论与总体总结

综合第 5 章实验结果可以看出，本文方法在六类代表性动作上总体实现了较为稳定的全身动作跟踪，其中周期性动作和静态平衡动作表现最好，而高动态跳跃、快速变向以及带有明显腾空落地过程的动作仍然更具挑战。误差主要集中在冲击响应、重心快速切换以及上肢与躯干的高频协同控制阶段。尽管如此，多模态参考约束、PPO 优化框架以及课程化稳定训练策略仍显著提升了全身动作的可执行性和稳定性，使机器人在复杂动作和扰动条件下保持了较高成功率与较好的泛化表现。

围绕“基于强化学习的人形机器人运动技能学习与泛化研究”这一课题，本文构建了从人体专家数据处理、动作重定向，到强化学习动作跟踪训练与实验验证的完整技术流程。针对人体运动数据无法直接用于机器人控制的问题，本文建立了 SMPL 人体模型与目标人形机器人之间的关键点拓扑映射关系，并通过体型拟合、逐帧动作重定向、关节限位约束和时序高斯滤波，将人体运动捕捉序列转换为机器人可执行的关节空间参考轨迹。在运动技能学习方面，本文基于 HumanoidVerse 和 Isaac Gym/MuJoCo 仿真环境构建全身动作跟踪任务，以重定向后的专家轨迹为参考状态，通过相位编码、多模态误差度量和高斯核奖励函数引导策略学习，并采用 PPO 算法优化控制策略。针对高动态动作训练中容易出现的局部最优和策略保守化问题，本文进一步引入参考状态初始化、动作偏离终止课程和安全正则项，以提升策略收敛效率和物理可行性。整体来看，本文提出的数据处理与强化学习训练流程能够较稳定地完成多类代表性动作的跟踪任务，并为后续更复杂的人形机器人运动技能学习研究奠定了基础。

6.2 研究局限性

尽管本文已经完成了从专家数据预处理到动作跟踪训练与测试的基本闭环，但当前研究仍存在若干局限。首先，本文实验主要集中在仿真环境中，尚未开展真实机器人平台验证，因此策略在真实执行器、传感器误差和复杂环境接触条件下的表现仍需进一步确认。其次，目前测试动作数量和场景范围仍然有限，虽然已经覆盖了静态平衡、周期行走和高动态动作，但对更长时序、更

强交互性和更复杂任务语义条件下的动作学习研究还不充分。再次，当前奖励设计和课程学习参数仍依赖人工经验进行设定，不同动作之间的统一权重配置和自动调参机制仍有进一步优化空间。

6.3 未来工作展望

未来工作可以从以下几个方向继续展开。第一，进一步扩展动作类别和测试场景，构建覆盖更多全身运动技能的参考动作库，并系统评估策略在复杂地形、连续任务和长时序动作中的表现。第二，开展跨仿真平台以及真机验证研究，分析不同动力学模型、执行器延迟和接触参数差异对策略迁移性能的影响，为后续 sim-to-sim 和 sim-to-real 打下基础。第三，继续优化奖励函数设计、课程学习策略和观测建模方式，提升策略在高动态动作下的稳定性与样本效率。第四，尝试将语言指令、视觉感知或多模态高层任务条件引入现有底层运动控制框架中，推动人形机器人从单一动作模仿逐步过渡到面向开放场景的具身智能控制。

参考文献

- [1] LI Z, PENG X B, ABBEEL P, et al. Robust and versatile bipedal jumping control through reinforcement learning[A]. 2023.
- [2] RADOSAVOVIC I, XIAO T, ZHANG B, et al. Real-world humanoid locomotion with reinforcement learning[J]. Science Robotics, 2024, 9(89): eadi9579.
- [3] CHENG X, JI Y, CHEN J, et al. Expressive whole-body control for humanoid robots [A]. 2024.
- [4] JI M, PENG X, LIU F, et al. ExBody2: Advanced expressive humanoid whole-body control[A]. 2024.
- [5] MAKОВIYCHUK V, WAWRZYNIAK L, GUO Y, et al. Isaac Gym: High performance gpu-based physics simulation for robot learning[A]. 2021.
- [6] RUDIN N, HOELLER D, REIST P, et al. Learning to walk in minutes using massively parallel deep reinforcement learning[C]//Conference on Robot Learning. PMLR, 2022: 91-100.
- [7] MARGOLIS G B, YANG G, PAIGWAR K, et al. Rapid locomotion via reinforcement learning[A]. 2022.
- [8] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[A]. 2017.
- [9] XIE Z, CLARY P, DAO J, et al. Learning locomotion skills for cassie: Iterative design and sim-to-real[C]//Conference on Robot Learning. PMLR, 2020: 317-329.
- [10] RADOSAVOVIC I, ZHANG B, SHI B, et al. Humanoid locomotion as next token prediction[A]. 2024.
- [11] ZHUANG Z, YAO S, ZHAO H. Humanoid parkour learning[A]. 2024.
- [12] GU X, WANG Y J, ZHU X, et al. Advancing humanoid locomotion: Mastering challenging terrains with denoising world model learning[A]. 2024.
- [13] LONG J, REN J, SHI M, et al. Learning humanoid locomotion with perceptive internal model[A]. 2024.
- [14] ZHANG Q, CUI P, YAN D, et al. Whole-body humanoid robot locomotion with human reference[C]//2024 IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2024: 11225-11231.

- [15] ZENG K, WANG Y, TAN H, et al.Prospects and technology of embodied intelligent humanoid robots driven by ai large models[J/OL].Science China Information Sciences, 2025, 55(5): 967-992.DOI: 10.1360/SSI-2024-0350.
- [16] MAHMOOD N, GHORBANI N, TROJE N F, et al.AMASS: Archive of motion capture as surface shapes[C/OL]//Proceedings of the IEEE/CVF International Conference on Computer Vision.2019: 5441-5450.DOI: 10.1109/ICCV.2019.00554.
- [17] PENG X B, ABBEEL P, LEVINE S, et al.DeepMimic: Example-guided deep reinforcement learning of physics-based character skills[J/OL].ACM Transactions on Graphics, 2018, 37(4): 1-14.DOI: 10.1145/3197517.3201311.
- [18] PENG X B, MA Z, ABBEEL P, et al.AMP: Adversarial motion priors for stylized physics-based character control[J].ACM Transactions on Graphics, 2021, 40(4): 1-20.
- [19] PENG X B, GUO Y, HALPER L, et al.ASE: Large-scale reusable adversarial skill embeddings for physically simulated characters[J].ACM Transactions on Graphics, 2022, 41(4): 1-17.
- [20] TESSLER C, GUO Y, NABATI O, et al.MaskedMimic: Unified physics-based character control through masked motion inpainting[J].ACM Transactions on Graphics, 2024, 43(6): 1-21.
- [21] LUO Z, CAO J, KITANI K, et al.Perpetual humanoid control for real-time simulated avatars[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision.2023: 10895-10904.
- [22] HE T, LUO Z, XIAO W, et al.Learning human-to-humanoid real-time whole-body teleoperation[A].2024.
- [23] TOBIN J, FONG R, RAY A, et al.Domain randomization for transferring deep neural networks from simulation to the real world[C]//2017 IEEE/RSJ International Conference on Intelligent Robots and Systems.IEEE, 2017: 23-30.
- [24] TAN J, ZHANG T, COUMANS E, et al.Sim-to-real: Learning agile locomotion for quadruped robots[A].2018.
- [25] LI Z, PENG X B, ABBEEL P, et al.Reinforcement learning for versatile, dynamic, and robust bipedal locomotion control[J].The International Journal of Robotics Research, 2024: 02783649241285161.

- [26] HE T, LUO Z, HE X, et al.OmniH2O: Universal and dexterous human-to-humanoid whole-body teleoperation and learning[A].2024.
- [27] ZHANG C, XIAO W, HE T, et al.WoCoCo: Learning whole-body humanoid control with sequential contacts[A].2024.
- [28] FU Z, ZHAO Q, WU Q, et al.HumanPlus: Humanoid shadowing and imitation from humans[A].2024.
- [29] HO J, ERMON S.Generative adversarial imitation learning[C]//Advances in Neural Information Processing Systems: Vol. 29.2016.
- [30] TODOROV E, EREZ T, TASSA Y.MuJoCo: A physics engine for model-based control[C/OL]//2012 IEEE/RSJ International Conference on Intelligent Robots and Systems.IEEE, 2012: 5026-5033.DOI: 10.1109/IROS.2012.6386109.
- [31] Genesis Authors.Genesis: A universal and generative physics engine for robotics and beyond[EB/OL].2024.<https://github.com/Genesis-Embodied-AI/Genesis>.
- [32] HWANGBO J, LEE J, DOSOVITSKIY A, et al.Learning agile and dynamic motor skills for legged robots[J].Science Robotics, 2019, 4(26): eaau5872.
- [33] YU W, KUMAR V C V, TURK G, et al.Sim-to-real transfer for biped locomotion [C]//2019 IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2019: 3503-3510.
- [34] DU Y, WATKINS O, DARRELL T, et al.Auto-tuned sim-to-real transfer[C]//2021 IEEE International Conference on Robotics and Automation.IEEE, 2021: 1290-1296.
- [35] PENG X B, ANDRYCHOWICZ M, ZAREMBA W, et al.Sim-to-real transfer of robotic control with dynamics randomization[C]//2018 IEEE International Conference on Robotics and Automation.IEEE, 2018: 3803-3810.
- [36] SILVER T, ALLEN K, TENENBAUM J, et al.Residual policy learning[A].2018.
- [37] JOHANNINK T, BAHL S, NAIR A, et al.Residual reinforcement learning for robot control[C]//2019 International Conference on Robotics and Automation.IEEE, 2019: 6023-6029.
- [38] ALAKUIJALA M, DULAC-ARNOLD G, MAIRAL J, et al.Residual reinforcement learning from demonstrations[A].2021.
- [39] WANG Y, WANG Z, LIU L, et al.TRAM: Global trajectory and motion of 3d humans from in-the-wild videos[C]//European Conference on Computer Vision. Springer, 2025: 467-487.

- [40] LOPER M, MAHMOOD N, ROMERO J, et al. SMPL: A skinned multi-person linear model[M]//Seminal Graphics Papers: Pushing the Boundaries, Volume 2. 2023: 851-866.

攻读学士学位期间取得创新性成果

截至论文撰写阶段，作者暂无与本课题直接相关的公开发表论文、授权专利或科研获奖成果。

哈尔滨工业大学本科毕业论文（设计）

原创性声明和使用权限

本科毕业论文（设计）原创性声明

本人郑重声明：此处所提交的本科毕业论文（设计）《基于强化学习的人形机器人运动技能学习与泛化研究》，是本人在导师指导下，在哈尔滨工业大学攻读学士学位期间独立进行研究工作所取得的成果，且毕业论文（设计）中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本毕业论文（设计）的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。本毕业论文（设计）对使用 AI 工具的情况进行了明确标注。

作者签名：

日期： 年 月 日

本科毕业论文（设计）使用权限

本科毕业论文（设计）是本科生在哈尔滨工业大学攻读学士学位期间完成的成果，知识产权归属哈尔滨工业大学。本科毕业论文（设计）的使用权限如下：

(1) 学校可以采用影印、缩印或其他复制手段保存本科生上交的毕业论文（设计），并向有关部门报送本科毕业论文（设计）；(2) 根据需要，学校可以将本科毕业论文（设计）部分或全部内容编入有关数据库进行检索和提供相应阅览服务；(3) 本科生毕业后发表与此毕业论文（设计）研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉本科毕业论文（设计）的使用权限，并将遵守有关规定。

作者签名：

日期： 年 月 日

导师签名：

日期： 年 月 日

致 谢

首先感谢导师奚月平老师在毕业设计选题、研究路线和论文撰写过程中给予的指导与帮助。老师在课题推进中提出了许多有价值的建议，使我能够更加清晰地理解人形机器人运动技能学习中的关键问题。

感谢哈尔滨工业大学（深圳）机器人与先进制造学院提供的学习与科研条件。感谢课题研究过程中给予我帮助的同学和朋友，他们在算法调试、实验分析和论文修改中提供了支持。

最后感谢家人在本科阶段对我的理解、鼓励和支持。